

BANCOS DE DADOS VETORES

Sobre o que é esta lição:

Você aprenderá o que são bancos de dados vetoriais, por que eles são essenciais para agentes e como eles dão suporte à memória de longo prazo e à pesquisa semântica em sistemas baseados em LLM, como o GPT.

O que é um banco de dados vetorial?

- Um tipo especial de banco de dados feito para IA e LLMs
- Armazena vetores (representações numéricas de significado) em vez de texto bruto
- Encontra informações com base no contexto e na similaridade, não em palavras-chave exatas
- Exemplo: como procurar lugares semelhantes à sua cafeteria favorita, não o nome exato dela

O que são vetores e lojas de vetores?

- Um vetor = um grupo de números que representam significado
- Um armazenamento de vetores = uma memória pesquisável onde esses vetores são salvos
- Ajuda a IA a comparar significados e encontrar informações relevantes, mesmo com palavras diferentes

Por que os agentes precisam deles:

- Os LLMs precisam de contexto e memória para gerar melhores respostas
- Os vetores permitem que os agentes recuperem pedaços relevantes de informações
- Permite pesquisa semântica: encontrar dados por significado em vez de correspondência exata
- Usado em agentes RAG (Retrieval-Augmented Generation) e assistentes inteligentes

Como funciona o processo de vetorização:

1. Comece com seus dados: PDFs, texto, JSON
2. Divida o conteúdo em pequenos pedaços
3. Incorpore cada pedaço em um vetor (usando um LLM)
4. Armazene os vetores em um banco de dados de vetores
5. Quando um usuário pergunta algo, converta-o em um vetor
6. Compare com vetores armazenados → encontre as melhores correspondências
7. Enviar pedaços relevantes para o GPT para gerar uma resposta

BANCOS DE DADOS VETORES



Bancos de dados de vetores populares comparados:

1. Pinha

- Totalmente gerenciado e desenvolvido para pesquisa semântica
- Fácil de usar, configuração plug-and-play
- Ótimo para agentes, chatbots e recomendações
- Melhor para: Agentes rápidos e em tempo real
- Usaremos Pinecone mais tarde no curso

2. Supabase + PGVector

- Não é um BD vetorial por padrão, mas suporta vetores via extensão
- Combina dados estruturados (como perfis de usuários) com pesquisa vetorial
- Código aberto, pode ser auto-hospedado
- Melhor para: casos de uso híbridos com necessidades de SQL e vetores
- Usaremos o Supabase neste curso

3. Qdrant

- Banco de dados vetorial auto-hospedado e de código aberto
- Rápido e poderoso para conjuntos de dados de médio a grande porte
- Funciona bem com LangChain e outras estruturas
- Melhor para: Controle total, sistemas de agentes personalizados
- Requer mais configuração do que o Pinecone



Resumo: Qual escolher?

- Pinecone – Ideal para pesquisa semântica rápida e gerenciada
- Supabase – Melhor para dados estruturados + vetoriais juntos
- Qdrant – Ideal para soluções auto-hospedadas e econômicas