

RAG – GERAÇÃO AUMENTADA DE RECUPERAÇÃO

Sobre o que é esta lição:

Você aprenderá o que é RAG, como ele torna os assistentes de IA mais inteligentes e como criar um fluxo de trabalho com tecnologia RAG no n8n para gerar respostas precisas a partir de dados internos ou em tempo real.

O que é RAG?

- **RAG = Recuperação + Geração**
- Primeiro, ele recupera dados reais (de documentos, APIs, bancos de dados)
- Em seguida, ele gera uma resposta com base nesses dados usando um LLM
- Isso evita alucinações e fornece respostas reais e atualizadas

Por que usar RAG?

- ChatGPT e outros LLMs possuem conhecimento de treinamento fixo
- Eles não podem acessar os dados ou documentos internos da sua empresa
- O RAG permite que eles pesquisem fontes externas e respondam com fatos
- Ótimo para informações dinâmicas, como políticas de reembolso, preços de ações, etc.

Como funciona o RAG?

1. O usuário faz uma pergunta
2. O LLM identifica quais informações são necessárias
3. O RAG recupera dados relevantes de documentos internos ou APIs
4. O LLM usa esses dados para gerar uma resposta
5. Resultado: Resposta precisa, contextual e atualizada

Assistente RAG no n8n – Componentes principais:

- **Agente de ferramentas** – O cérebro do assistente com instruções do sistema
- **Modelo de Chat** – modelo OpenAI que gera a resposta final
- **Memória de bate-papo do Postgres** – armazena interações anteriores do usuário
- **Supabase Vector Store** – memória pesquisável por IA a partir de documentos
- **Nó de incorporação** – Converte texto em vetores para pesquisa semântica

RAG – GERAÇÃO AUMENTADA DE RECUPERAÇÃO

✅ O que o RAG possibilita?

- Respostas em tempo real a partir de dados internos
- Automação mais inteligente e sensível ao contexto
- Assistentes que não adivinham – eles buscam a resposta correta

🔥 Casos de uso do mundo real:

- Suporte ao cliente – Respostas baseadas em políticas atuais e tickets anteriores
- Chatbots – Obtenha as últimas atualizações (notícias, previsão do tempo, inventário)
- Educação e pesquisa – Recupere o material mais relevante
- E-commerce – Informações sobre ações, recomendações personalizadas
- Finanças – Taxas de juros atualizadas, informações da conta
- Saúde e seguro – Detalhes da apólice ou informações do paciente
- Legal e conformidade – Últimas leis ou termos contratuais